Sprawozdanie z projektu

Wiktor Płużek

1 Spis treści

2 Cel projektu

Celem projektu jest bliższe poznanie działania uczenia maszynowego, a dokładniej sieci neuronowych, w celu rozwiązywania problemów związanych z klasyfikacją, regresją czy analizą.

2.1 Wybrany problem

Wybranym przeze mnie problemem jest przetwarzanie obrazów, a dokładniej klasyfikacja typu pokemona na podstawie jego zdjęcia.

Dla przykładowego pokemona Beedrill o typach Robak, Trujący, ze zdjęciem:

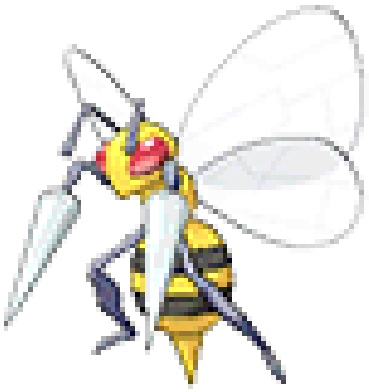

Program powinien poprawnie sklasyfikować typ pokemona jako jeden z dwóch: Robak lub Trujący.

3 PRZYGOTOWANIE DANYCH

3.1 WYBÓR ZBIORÓW DANYCH

Najważniejszą rzeczą potrzebną do dobrej klasyfikacji jest dobry zbiór danych do nauki modelu. W tym celu pobrałem ze strony ze zbiorami danych dwa zbiory zdjęć pokemonów:

- Ponad 2500 zdjęć, około 5-6 zdjęć dla każdego pokemona: https://www.kaggle.com/datasets/hlrhegemony/pokemon-image-dataset

- Kolejne 809 zdjęć, po 1 dla każdego pokemona, jednak ten zbiór zawierał bardzo użyteczny zbiór jaki pokemon posiada które typy, dzięki czemu zaoszczędziłem dużo czasu na przepisywaniu tych informacji z wiki. https://www.kaggle.com/datasets/vishalsubbiah/pokemon-images-and-types?resource=download

3.2 Różnice w strukturze zapisu zbiorów

Niestety forma zapisu zdjęć nie była ze sobą kompatybilna, ponieważ pierwszą wersję programu zrobiłem na mniejszym zbiorze, w którym zdjęcia miały nazwę nazwa_pokemona.png, tak też zaimplementowałem w programie odnajdywanie poprawnych typów – po nazwie pokemona zawartej w nazwie zdjęcia.

Drugi zbiór – większy, był nieco inaczej zorganizowany, gdyż miał on strukturę Folder o nazwie pokemona / 0.jpg, 1.jpg … ,
Musiałem więc napisać niewielki skrypt, który zamienił tę strukturę na taką, która odpowiadałaby mojej implementacji

```
import os

for dir in os.listdir('./images'):
    for img in os.listdir('./images/' + dir):
        olddir = './images/' + dir + '/' + img
        newdir = './images_new/' + dir + '.' + img.split('.')[0] + '.' +
img.split('.')[1]
        os.rename(dir, newdir)
```

Skrypt ten zwyczajnie brał każde zdjęcie z folderu o nazwie pokemona i przenosił je ze zmienioną nazwą z 0.jpg -> nazwa_pokemona.0.jpg do folderu ze wszystkimi zdjęciami pokemonów.

Dodatkowo, większy zbiór zawierał kilkadziesiąt pokemonów, które nie były zawarte w arkuszu danych z typami pokemonów, musiałem więc niestety ręcznie je tam dodawać.

4 Implementacja sieci neuronowych

4.1 Przypisywanie typów pokemona po nazwie pliku

Do nauki ważne jest, aby podczas treningu model wiedział, czy jego predykcja jest poprawna – w tym celu razem ze zdjęciem w zbiorze treningowym przesyłane są faktyczne typy pokemona, które są wyciągane z arkusza, w którym każdemu pokemonowi przypisane są jego typy

```
def label_img(img):
    word_label = img.split('.')[0].lower()
    label_arr = [0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0]
    for i in pokemon_dict[word_label]:
        for index in range(0, len(pokemon_types)):
```

```
            if pokemon_types[index] == i:
                label_arr[index] = 1
    return label_arr
```

4.2 TWORZENIE ZBIORÓW TRENINGOWYCH I TESTOWYCH

Ze zbioru wszystkich 3350 zdjęć, 80% z nich użyłem do zbioru treningowego

```
def create_train_data():
    training_data = []
    for img in tqdm(os.listdir(IMAGES)[:int(len(os.listdir((IMAGES))) *
0.8)]):
        label = label_img(img)
        path = os.path.join(IMAGES, img)
        img = cv2.imread(path)
        img = cv2.cvtColor(img, cv2.COLOR_BGR2RGB)
        img = cv2.resize(img, (IMG_SIZE, IMG_SIZE))
        training_data.append([np.array(img), np.array(label)])
    shuffle(training_data)
    np.save('train_data.npy', training_data)
    print("create_train_data done")
    return training_data
```

A 20% z nich do zbioru testowego

```
def process_test_data():
    testing_data = []
    for img in tqdm(os.listdir(IMAGES)[int(len(os.listdir((IMAGES))) *
0.8):]):
        path = os.path.join(IMAGES, img)
        label = label_img(img)
        img = cv2.imread(path)
        img = cv2.cvtColor(img, cv2.COLOR_BGR2RGB)
        img = cv2.resize(img, (IMG_SIZE, IMG_SIZE))
        testing_data.append([np.array(img), np.array(label)])

    shuffle(testing_data)
    np.save('test_data.npy', testing_data)
    print("process_test_data done")
    return testing_data
```

4.3 TWORZENIE WARSTW SIECI

Do implementacji sieci neuronowych postanowiłem wykorzystać bibliotekę tensorflow, mając nadzieję na późniejsze uruchomienie uczenia na karcie graficznej dla lepszych efektów.

Początkowo zastosowałem bardzo proste sieci – niewiele warstw oraz niewiele iteracji.

10 iteracji, ok. 3 min., skuteczność ~10%

```
convnet = input_data(shape=[None, IMG_SIZE, IMG_SIZE, 3], name='input')

convnet = conv_2d(convnet, 32, 4, activation='relu')
convnet = max_pool_2d(convnet, 4)

convnet = conv_2d(convnet, 64, 3, activation='relu')
convnet = max_pool_2d(convnet, 3)

convnet = fully_connected(convnet, 8192, activation='relu')

convnet = fully_connected(convnet, 18, activation='softmax')
convnet = regression(convnet, optimizer='adam', learning_rate=LR,
loss='categorical_crossentropy', name='targets')
```

Następnie postanowiłem stworzyć bardziej złożone warstwy – więcej oraz złożone z większej ilości połączeń.

Ilość iteracji – 20, Ok. 10 min., skuteczność ~18%

```
convnet = input_data(shape=[None, IMG_SIZE, IMG_SIZE, 3], name='input')

convnet = conv_2d(convnet, 32, 8, activation='relu')
convnet = max_pool_2d(convnet, 8)

convnet = conv_2d(convnet, 64, 10, activation='relu')
convnet = max_pool_2d(convnet, 10)

convnet = conv_2d(convnet, 128, 8, activation='relu')
convnet = max_pool_2d(convnet, 8)

convnet = conv_2d(convnet, 256, 8, activation='relu')
convnet = max_pool_2d(convnet, 8)

convnet = conv_2d(convnet, 128, 8, activation='relu')
convnet = max_pool_2d(convnet, 8)

convnet = conv_2d(convnet, 64, 6, activation='relu')
convnet = max_pool_2d(convnet, 6)

convnet = conv_2d(convnet, 32, 5, activation='relu')
convnet = max_pool_2d(convnet, 5)

convnet = fully_connected(convnet, 1024, activation='relu')

convnet = fully_connected(convnet, 18, activation='softmax')
convnet = regression(convnet, optimizer='adam', learning_rate=LR,
loss='categorical_crossentropy', name='targets')
```

Metodą prób i błędów, zauważyłem jednak, że sieć osiągała najlepsze wyniki dla średnio skomplikowanej sieci z większą ilością iteracji.

skuteczność ~21%

```
convnet = input_data(shape=[None, IMG_SIZE, IMG_SIZE, 3], name='input')

convnet = conv_2d(convnet, 32, 6, activation='relu')
convnet = max_pool_2d(convnet, 6)

convnet = conv_2d(convnet, 64, 12, activation='relu')
convnet = max_pool_2d(convnet, 12)

convnet = conv_2d(convnet, 64, 6, activation='relu')
convnet = max_pool_2d(convnet, 6)

convnet = conv_2d(convnet, 32, 4, activation='relu')
convnet = max_pool_2d(convnet, 4)

convnet = fully_connected(convnet, 4096, activation='relu')

convnet = fully_connected(convnet, 18, activation='softmax')
convnet = regression(convnet, optimizer='adam', learning_rate=LR,
loss='categorical_crossentropy', name='targets')
```

Niestety pomimo wielu prób, obejrzanych poradników i wpisów na stackoverflow, nie udało mi się uruchomić uczenia sieci na karcie graficznej, więc ograniczyłem się dla tej sieci jedynie do 40 iteracji – co trwało ok. 15 min.

Jednak okazało się, że po tej ilości iteracji, model został przetrenowany dla danych treningowych, więc próbowałem zmniejszać tę ilość aż osiągnąłem lepsze wartości – przy 25 iteracjach, co zajęło jedynie ok. 8 min., program osiągnął dotychczas najwyższe – 30% skuteczności.

Co ciekawe, czasami, bez żadnych zmian w sieci, model przypisywał każdemu pokemonowi ten sam typ, przez co nawet po 30 iteracjach zdobywał zaledwie ~7% skuteczności…

Uruchomienie modelu:

```
train = train_data
test = test_data

X = np.array([i[0] for i in train]).reshape(-1, IMG_SIZE, IMG_SIZE, 3)
Y = [i[1] for i in train]
```

```
test_x = np.array([i[0] for i in test]).reshape(-1, IMG_SIZE, IMG_SIZE, 3)
test_y = [i[1] for i in test]

model.fit({'input': X}, {'targets': Y}, n_epoch=15,
validation_set=({'input': test_x}, {'targets': test_y}),
          snapshot_step=500, show_metric=True, run_id="pokemon")
```

Wyświetlenie wyników:

```
fig = plt.figure()

sum = [0,0]
for num, data in enumerate(test_data[:81]):
    actual_type = data[1]
    img_data = data[0]

    y = fig.add_subplot(9, 9, num + 1)
    orig = img_data
    data = img_data.reshape(IMG_SIZE, IMG_SIZE, 3)
    model_out = model.predict([data])[0]
    # 'Normal', 'Fire', 'Water', 'Grass', 'Flying', 'Fighting', 'Poison',
'Electric', 'Ground', 'Rock',
    # 'Psychic', 'Ice', 'Bug', 'Ghost', 'Steel', 'Dragon', 'Dark', 'Fairy']

    if np.max(model_out) == model_out[0]:
        if actual_type[0] == 1:
            sum[0]+=1
        str_label = 'Normal'
    elif np.max(model_out) == model_out[1]:
        if actual_type[1] == 1:
            sum[0]+=1
        str_label = 'Fire'
```

…

```
    elif np.max(model_out) == model_out[17]:
        if actual_type[17] == 1:
            sum[0]+=1
        str_label = 'Fairy'
    sum[1]+=1

    y.imshow(orig)
    plt.title(str_label)
    y.axes.get_xaxis().set_visible(False)
    y.axes.get_yaxis().set_visible(False)

print("Guessed % = " + str(sum[0]/sum[1]) + " Random guessing % = " +
str(1/18))
plt.show()
```

5 PODSUMOWANIE

Po wielu testach dla różnych kombinacji warstw konwolucyjnych i poolingowych, doszedłem do wniosku, że moja implementacja rozpoznawania typów pokemonów nie radziła sobie najlepiej – najlepszym osiągniętym przez nią wynikiem była celność zgadnięć na poziomie 30%, co faktycznie jest sporym

przeskokiem ponad losowym strzelaniem, które dla obecnych 18 typów pokemonów wyniosłoby ok. 5,6%. Jednak osobiście uważam, że taka skuteczność nie jest niczym wybitnym, może gdybym posiadał większe zasoby obliczeniowe, lub lepszy zbiór danych do nauki, byłbym w stanie osiągnąć lepszy wynik.

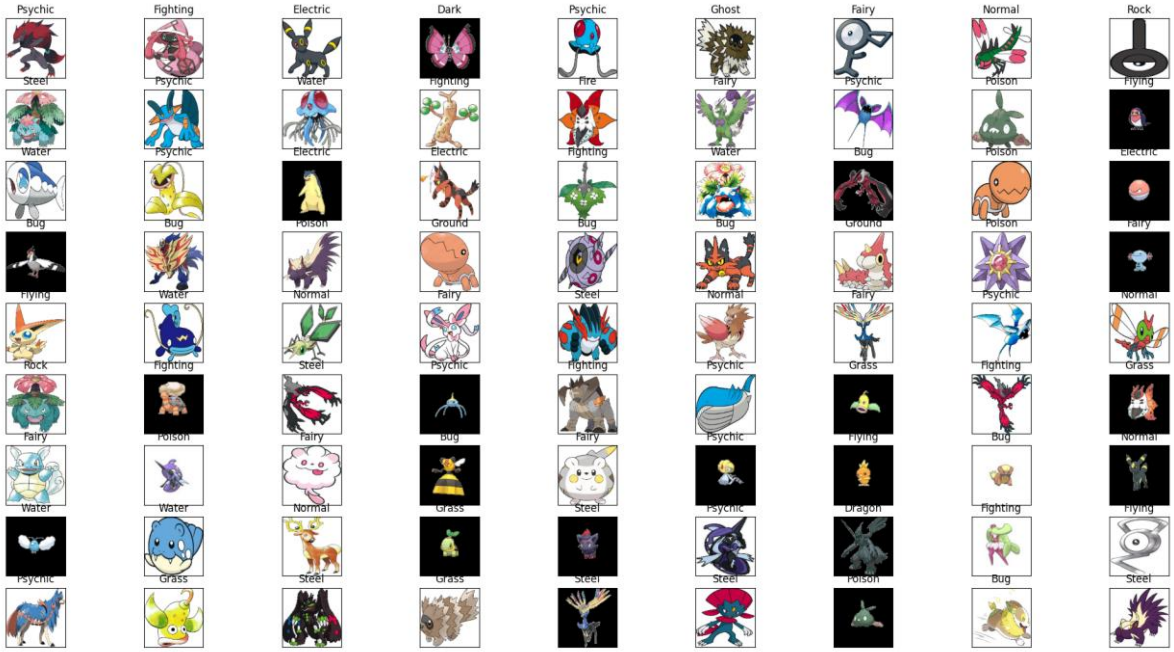

Niemniej jednak, uważam że zastosowania uczenia maszynowego i sieci neuronowych mają ogromny potencjał w dzisiejszym świecie, gdzie potrzebna jest klasyfikacja i wykrywanie najróżniejszych obiektów przez maszyny, które mogą być odpowiedzialne m.in. za nasze bezpieczeństwo.